

Automaty a gramatiky (BI-AAG)

6. Vlastnosti regulárních jazyků

Jan Holub

Katedra teoretické informatiky
Fakulta informačních technologií
ČVUT v Praze



© Jan Holub, 2025

Pumping lemma – podstata problému

Předpokládejme, že by jazyk $L = \{0^n 1^n : n \geq 1\}$ byl regulární.

V takovém případě by jazyk L byl přijímaný konečným automatem $\mathcal{A}$ s m stavy.

Pumping lemma – podstata problému

Nechť automat $\mathcal{A}$ čte posloupnost 0^m . Při čtení této posloupnosti je průchod jednotlivými stavy následující:

ε p_0

0 p_1

00 p_2

... ...

0^m p_m

t.j., $\exists i < j : p_i = p_j$ (Princip holubníku). Označme takový stav q .

Pumping lemma – vyřešení problému

Předpokládejme dále, že po následném přečtení vstupní posloupnosti 1^i se automat dostane ze stavu q do stavu r .

Platí, že:

- Pokud by stav r byl koncovým stavem, pak by automat přijímal větu 0^j1^i , což nechceme.
- Pokud by stav r nebyl koncovým stavem, pak by automat nepřijal větu 0^i1^i , což také ale nechceme.

Proto jazyk $L = \{0^n1^n : n \geq 1\}$ nemůže být regulární.

□

Pumping lemma formálně


Pumping lemma

Nechť L je regulární jazyk. Pak pro jazyk L existuje konstanta $p \geq 1$ taková, že pro každou větu $w \in L$ platí:

Jestliže $|w| \geq p$, pak w lze zapsat ve tvaru $w = xyz$ tak, že:

- $y \neq \varepsilon$ (t.j. $|y| \geq 1$),
- $|xy| \leq p$,
- $\forall k \geq 0$ platí, že $xy^kz \in L$.

Pumping lemma neformálně



Použití PL k důkazu, že L není regulární

Důkaz, že jazyk $L = \{0^n 1^n : n \geq 1\}$ není regulární

Předpokládejme, že L je regulární. Pak pomocí Pumping lemmatu musí platit, že existuje konstanta $p \geq 1$ taková, že pro každou větu $w \in L$ platí, že:

Jestliže $|w| \geq p$, pak w lze zapsat ve tvaru $w = xyz$ tak, že:

- $y \neq \varepsilon$ (t.j. $|y| \geq 1$),
- $|xy| \leq p$,
- $\forall k \geq 0$ platí, že $xy^kz \in L$.

Věta $w = 0^p 1^p \in L$ je zřejmě delší než p , a tudíž musí splňovat požadavky PL. K důkazu, že L není regulární, zkusíme všechna možná rozdělení věty w na xyz . Musíme pak dokázat, že každé z nich porušuje alespoň jednu z podmínek.

Použití PL k důkazu, že L není regulární

Důkaz, že jazyk $L = \{0^n 1^n : n \geq 1\}$ není regulární (pokr.)

Rozdělení buď nesplňuje některou z prvních dvou podmínek, nebo

- xy je neprázdná posloupnost nul,
- y je neprázdná posloupnost nul,
- z obsahuje všechny jedničky.

Ale pak xy^0z (čili odstraníme y z $w = xyz$) nepatří do L (protože počet nul v xy^0z je určitě menší než počet jedniček)!

Proto L není regulární jazyk.



Použití PL k důkazu, že L není regulární

Důkaz, že jazyk $L = \{1^m : m \text{ je prvočíslo}\}$ není regulární

Předpokládejme, že L je regulární. Pak pomocí Pumping lemmatu musí platit, že existuje konstanta $p \geq 1$ taková, ... (viz Pumping lemma):

Předpokládejme větu $w = 1^m$ pro prvočíslo $m \geq p + 2$.

Nechť $w = xyz$ je libovolné rozdělení splňující $|xy| \leq p$ a $1 \leq |y|$. Uvažme „napumpovanou“ větu $w_1 = xy^{m-|y|}z$. Ukážeme, že w_1 nepatří do L , což rozporuje Pumping lemma.

Použití PL k důkazu, že L není regulární

Důkaz, že jazyk $L = \{1^m : m \text{ je prvočíslo}\}$ není regulární (pokr.)

Uvažujme délku věty $w_1 = xy^{m-|y|}z$. Pak platí, že

$$\begin{aligned} |xy^{m-|y|}z| &= \\ |xz| + (m - |y|) * |y| &= \\ (m - |y|) + (m - |y|) * |y| &= \\ (m - |y|) * (1 + |y|). \end{aligned}$$

$|w_1|$ by bylo prvočíslem, pouze kdyby buďto $(m - |y|) = 1$, nebo $(1 + |y|) = 1$.

- $(1 + |y|) \neq 1$, protože $|y| \geq 1$.
- $m \geq p + 2$, $|y| \leq |xy| \leq p$, proto $m - |y| \geq p + 2 - p = 2$.

Pro libovolné rozdělení $w = xyz \in L$ podle prvních dvou podmínek PL platí, že $xy^{m-|y|}z \notin L$.

Proto, L **není regulární**. □

Použití PL k důkazu, že L není regulární

Příklad jazyka, který splňuje podmínky PL, ale není regulární.

■ $L = \{u : u = a^+b^ic^i \vee u = b^ic^j, 0 \leq i, 0 \leq j\}$

Kontrolní otázka

Jak velká je konstanta p v Pumping lemmatu pro *konečný* jazyk?

(Poznámka: Každý konečný jazyk je regulární, a proto pro něj musí platit podmínky Pumping lemmatu.)

Myhill-Nerodova věta: motivace

- MNv charakterizuje některé zásadní vztahy mezi konečnými automaty nad abecedou Σ a jistými ekvivalenčními relacemi nad řetězci ze Σ^* ,
- MNv popisuje některé z nutných a postačujících podmínek pro to, aby daný jazyk byl jazykem regulárním (používá se často k důkazu neregularity jazyka),
- MNv poskytuje formální bázi pro elegantní důkaz existence unikátního (až na isomorfismus) minimálního DKA k danému regulárnímu jazyku.

Ekvivalence

Definice (Ekvivalence – opakování z BI-DML)

Ekvivalence $\sim$ je binární relace, která je *reflexivní, symetrická a tranzitivní*.

Definice (Třída ekvivalence – opakování z BI-DML)

Třída ekvivalence prvku a (značíme $[a]$) na množině X je podmnožina X obsahující všechny prvky ekvivalentní s a .

Definice (Rozklad množiny)

Množina všech tříd ekvivalence v X se nazývá *rozklad množiny* X podle $\sim$ a značí se $X/\sim$.

Definice (Index ekvivalence)

Index ekvivalence $\sim$ je počet tříd ekvivalence v $\Sigma/\sim$. Jestliže existuje nekonečně mnoho tříd ekvivalence, definujeme index jako ∞ .

Pravá kongruence a prefixová ekvivalence

Definice (Pravá kongruence)

Nechť Σ je abeceda a $\sim$ je ekvivalence na Σ^* . Ekvivalence $\sim$ je *pravou kongruencí*, jestliže pro každé $u, v, w \in \Sigma^*$ platí, že:

$$u \sim v \Rightarrow uw \sim vw$$

Definice (Prefixová ekvivalence)

Nechť L je libovolný (ne nutně regulární) jazyk nad abecedou Σ . Definujeme *prefixovou ekvivalenci* pro L jako relaci $\sim_L$ na množině Σ^* následovně:

$$u \sim_L v \Leftrightarrow \forall w \in \Sigma^* : uw \in L \Leftrightarrow vw \in L$$

Pozorování

Pro každý jazyk L je prefixová ekvivalence pravou kongruencí.

Myhill-Nerodova věta

Myhill-Nerodova věta

Nechť L je jazyk nad Σ . Pak následující tvrzení jsou ekvivalentní:

1. L je jazyk přijímaný deterministickým konečným automatem.
2. L je sjednocením některých tříd rozkladu určeného pravou kongruencí na Σ^* s konečným indexem.
3. Relace $\sim_L$ má konečný index.

Důkaz

Dokážeme následující implikace:

- $1 \Rightarrow 2.$
- $2 \Rightarrow 3.$
- $3 \Rightarrow 1.$

Myhill-Nerodova věta: $1 \Rightarrow 2$

Je-li L přijímán DKA, pak L je sjednocením některých tříd rozkladu určeného pravou kongruencí na Σ^* s konečným indexem.

Zavedme si pro DKA $M = (Q, \Sigma, \delta, q_0, F)$ zobecněnou přechodovou funkci $\hat{\delta}$.
 $\hat{\delta} : Q \times \Sigma^* \rightarrow Q$ tak, že
 $\forall q_1, q_2 \in Q, w \in \Sigma^* : \hat{\delta}(q_1, w) = q_2 \Leftrightarrow (q_1, w) \vdash_M^* (q_2, \varepsilon).$

Myhill-Nerodova věta: $1 \Rightarrow 2$

Důkaz

Pro daný jazyk L přijímaný DKA M zkonstruujeme $\sim$ s potřebnými vlastnostmi:

- Nechť $M = (Q, \Sigma, \delta, q_0, F)$ je úplný DKA.
- Zvolíme $\sim$ jako binární relaci na Σ^* takovou, že $u \sim v \Leftrightarrow \hat{\delta}(q_0, u) = \hat{\delta}(q_0, v)$.
- Ukážeme, že $\sim$ má potřebné vlastnosti:
 - ◆ $\sim$ je ekvivalence: je reflexivní, tranzitivní a symetrická.
 - ◆ $\sim$ má konečný index: třídy rozkladu odpovídají stavům DKA.
 - ◆ $\sim$ je pravá kongruence: Nechť $u \sim v$ a $a \in \Sigma$. Pak $\hat{\delta}(q_0, ua) = \delta(\hat{\delta}(q_0, u), a) = \delta(\hat{\delta}(q_0, v), a) = \hat{\delta}(q_0, va)$ a tedy $ua \sim va$.
 - ◆ L je sjednocením některých tříd ekvivalence $\Sigma^*/\sim$ – těch, které odpovídají F .

Myhill-Nerodova věta: $2 \Rightarrow 3$

Existuje-li relace $\sim$ splňující podmínku 2, pak $\sim_L$ má konečný index.

Důkaz

- Pro všechny $u, v \in \Sigma^*$ takové, že $u \sim v$, platí $u \sim_L v$:
 - ◆ Nechť $u \sim v$. Ukážeme, že také $u \sim_L v$, tj.
 $\forall w \in \Sigma^* : uw \in L \Leftrightarrow vw \in L$.
 - ◆ Víme, že $uw \sim vw$, a protože L je sjednocením některých tříd rozkladu $\Sigma^*/\sim$, platí také $uw \in L \Leftrightarrow vw \in L$.
- Víme tedy, že $\sim \subseteq \sim_L$ (tj. $\sim_L$ je největší pravá kongruence s danými vlastnostmi).
- Každá třída $\sim$ je obsažena v nějaké třídě $\sim_L$.
- Index $\sim_L$ nemůže být větší než index $\sim$.
- $\sim$ má konečný index, a tedy i $\sim_L$ má konečný index.

Myhill-Nerodova věta: $3 \Rightarrow 1$

Má-li $\sim_L$ konečný index, pak L je přijímán nějakým konečným automatem.

Důkaz

■ Vytvoříme $M = (Q, \Sigma, \delta, q_0, F)$ přijímající L :

- ◆ $Q = \Sigma^* / \sim_L$ (stavy jsou třídy rozkladu Σ^* relací $\sim_L$),
- ◆ $\forall u \in \Sigma^*, a \in \Sigma : \delta([u], a) = [ua]$,
- ◆ $q_0 = [\varepsilon]$,
- ◆ $F = \{[x] \mid x \in L\}$.

■ Uvedená konstrukce je korektní, tj. $L = L(M)$:

- ◆ Indukcí nad délkou slova v ukážeme, že $\forall v \in \Sigma^* : \hat{\delta}([\varepsilon], v) = [v]$.
- ◆ $v \in L \Leftrightarrow [v] \in F \Leftrightarrow \hat{\delta}([\varepsilon], v) \in F$. □

Důkaz neregularity pomocí M.-N. věty

Dokažte, že jazyk $L = \{0^n 1^n : n \geq 1\}$ není regulární.

Důkaz

- Žádné řetězce $\varepsilon, 0, 0^2, 0^3, \dots$ nejsou $\sim_L$ -ekvivalentní, protože $0^i 1^i \in L$, ale $0^j 1^i \notin L$ pro $i \neq j$.
- $\sim_L$ má tedy nekonečně mnoho tříd (neboli nekonečný index).
- Podle Myhill-Nerodovy věty tedy nemůže být jazyk L přijímán žádným konečným automatem. □

M.-N. věta a minimalita DKA

Věta (2. varianta M.-N. věty)

Počet stavů libovolného minimálního DKA přijímajícího jazyk L je roven indexu $\sim_L$. (Takový DKA existuje právě tehdy, když je index $\sim_L$ konečný.)

Důkaz

- Každý DKA (bez nedosažitelných stavů) určuje jistou pravou kongruenci s konečným indexem a naopak.
- Je-li L regulární, $\sim_L$ je největší pravou kongruencí s konečným indexem takovou, že L je sjednocením některých tříd příslušného rozkladu.
- Konečný automat, který odpovídá $\sim_L$ (viz důkaz $3 \Rightarrow 1$ M.-N. věty), je tedy minimální konečný automat přijímající L . □